



NVIDIA L40S



为数据中心赋予出色的 AI 和图形性能

生成式 AI 正在推动转型变革，为各行各业开辟领域迎来新的机遇。要借助 AI 实现转型，企业需要更多的计算资源、更大的规模和更为广泛的功能来满足不断增长的多种复杂工作负载的需求。

NVIDIA L40S GPU 是一款适用于数据中心的功能强大的通用型 GPU，可为下一代 AI 应用提供端到端加速服务 – 从生成式 AI 以及模型训练和推理到 3D 图形、渲染和视频应用。

加速下一代工作负载

- > 生成式 AI
- > 大语言模型 (LLM)
- > 训练和推理
- > NVIDIA Omniverse™ Enterprise
- > 渲染和 3D 图形
- > 串流和视频内容



微调 LoRA (GPT-40B、GPT-175B)：global trainbatch size：128 (序列)，序列长度：256 (tokens)。NVIDIA HGX™ A100 (8 片 A100) 与搭载了 4 片 L40S GPU 两套系统对比。性能参数基于预发行版本，可能会发生变化。

Stable Diffusion v2.1。相对加速用于生成 512 x 512 分辨率的图像。NVIDIA HGX A100 (8 片 A100) 与搭载了 4 片 L40S GPU 两套系统对比。性能参数基于预发行版本，可能会发生变化。

由 NVIDIA Ada Lovelace 架构提供支持

第四代 Tensor Core

针对结构化稀疏和优化的 TF32 格式提供硬件支持，为 AI 和数据科学模型训练提供开箱即得的性能提升。可利用 DLSS 技术加速 AI 增强型图形功能，从而在特定应用中提供更高的分辨率和更出色的性能。

第三代 RT Core

增加的吞吐量以及并发光线追踪和着色功能可提升光线追踪性能，从而加快产品设计以及建筑、工程和施工工作流程的渲染。借助硬件加速的动态模糊和令人惊叹的实时动画，查看逼真的设计。

Transformer 引擎

Transformer 引擎可显著加速 AI 性能，并提高训练和推理的显存利用率。凭借 Ada Lovelace 第四代 Tensor Cores 的强大功能，Transformer 引擎可以智能扫描 Transformer 架构神经网络的各个层，并在 FP8 和 FP16 精度之间自动重铸，从而提供更快 AI 性能并加速训练和推理。



数据中心就绪

L40S GPU 针对全天候企业数据中心运营进行了优化，并由 NVIDIA 提供设计、构建、测试和支持，以确保更大限度地实现出色的性能、耐用性和正常运行时间。L40S GPU 符合最新的数据中心标准，支持网络设备构建系统 (NEBS) 3 级标准，并采用了信任根技术的安全启动功能，可为数据中心提供额外的安全保护层。

技术规格	
GPU 架构	NVIDIA Ada Lovelace 架构
GPU 显存	支持 ECC 的 48GB GDDR6
显存带宽	864GB/ 秒
连接接口	PCIe 4.0 x16: 64GB/s 双向
NVIDIA Ada Lovelace 架构 基于 CUDA® 核心	18,176
NVIDIA 第三代 RT Core	142
NVIDIA 第四代 Tensor Core	568
RT Core 性能 TFLOPS	209
FP32 TFLOPS 单精度浮点运算能力	91.6
TF32 Tensor Core TFLOPS	183 366*
BFLOAT16 Tensor Core TFLOPS	362.05 733*
FP16 Tensor Core	362.05 733*
FP8 Tensor Core	733 1,466*
INT8 Tensor TOPS 峰值运算能力	733 1,466*
INT4 Tensor TOPS 峰值运算能力	733 1,466*
外形规格	11.2厘米 (高) x 26.7厘米 (长), 双插槽
显示端口	4 x DisplayPort 1.4a
最大功耗	350W
电源接口	16 针
散热	被动
vGPU 软件支持	是
支持的 vGPU 配置文件	查看 vGPU 许可指南
NVENC NVDEC	3x 3x (包括 AV1 编码和解码)
使用信任根进行安全启动	是
NEBS	3 级标准
MIG 支持	否
支持 NVIDIA® NVLink®	否

* 采用稀疏技术

准备好开始了吗？

如需详细了解 NVIDIA L40S，请访问
www.nvidia.cn/data-center/l40s/

© 2023 NVIDIA Corporation 及其关联公司。保留所有权利。NVIDIA、NVIDIA 徽标、CUDA、HGX、NVLink 和 Omniverse 均为 NVIDIA Corporation 及其关联公司在美国和其他国家 / 地区的商标和 / 或注册商标。其他公司和产品名称可能是其各自所有者的商标。2907810. 2023 年 8 月

